MLJAR 与 TabularX 完整工具包对比

Credit Scoring 数据集实验报告

TabularX 机器学习课程项目

实验日期：2026 年 9 月 29 日

目 录

第 1 章 实验概述 1
1.1 数据集与任务 1
1.2 比较范围与原则 1
第 2 章 实验结果 2
2.1 外部测试集表现 2
2.2 可解释性与可信性工件盘点 2
第 3 章 工具优缺点与结果解读 4
3.1 TabularX 4
3.2 MLJAR 4
第 4 章 结　论 5
来　源 6

第 1 章　实验概述

1.1　数据集与任务

数据集：Credit Scoring（OpenML dataset 31（credit-g），二分类）。 Credit Scoring 数据集包含 1,000 名信贷申请人的 20 个金融与人口统计特征，目标是预测申请人的信用风险为 good 或 bad。数据按固定随机种子 42 划分为 80% 开发集和 20% 外部测试集，外部测试集共 200 条记录。

1.2　比较范围与原则

实验比较 MLJAR 与 TabularX 两个完整工具包，范围包括预处理、模型搜索与选择、解释、公平性适用性、可信审计、模型持久化、报告和证据交付。双方使用同一数据划分，并运行 Random Forest、XGBoost、LightGBM 和 CatBoost。外部测试集不参与训练、调参和选模，只在最终模型锁定后评估一次。

性能指标只描述本次固定配置。主要比较对象是实际生成并能够核对的解释性与可信性工件。

第 2 章　实验结果

2.1　外部测试集表现

表 2.1　共同外部测试集上的模型表现

工具	最终模型	Accuracy	Balanced Accuracy	Macro-F1	ROC-AUC
TabularX	CatBoost	0.7450	0.6321	0.6427	0.7393
MLJAR	Ensemble	0.7450	0.5940	0.5899	0.7656

本次固定配置下，TabularX 与 MLJAR 的 Accuracy 分别为 0.7450 和 0.7450，ROC-AUC 分别为 0.7393 和 0.7656。类别不均衡任务还应结合 Balanced Accuracy、Macro-F1 与混淆矩阵解读；该结果不构成普遍性能排名。

2.2　可解释性与可信性工件盘点

表 2.2　本次运行实际观察到的工件

工件	TabularX	MLJAR	说明
最佳模型及可重载文件	已生成	已生成	两者均保存最终模型；TabularX 另行核验模型接收原始表格后的预测一致性。
候选模型与验证分数	已生成	已生成	TabularX 保存 model_scores.json；MLJAR 保存 leaderboard.csv 或参数记录。
预处理记录	已生成	已生成	两者均提供本次运行可查阅的预处理记录。
特征重要性	已生成	已生成	两者均生成特征重要性文件或图。
SHAP	已生成	已生成	两者本次均观察到 SHAP 工件；覆盖范围以实际模型目录为准。
ALE	未观察到	未观察到	本次固定配置下，两者均未观察到 ALE 工件。
学习曲线或调参轨迹	已生成	已生成	TabularX 输出调参轨迹；MLJAR 输出学习曲线。

工件	TabularX	MLJAR	说明
混淆矩阵	已生成	已生成	分类任务用于核对各类别预测错误；回归任务不适用。
公平性	已生成	已生成	按 age_25_plus 年龄分组生成公平性与群体覆盖结果；该审计分组不作为模型输入。
泄露、划分与评估协议审计	已生成	未观察到	TabularX 将数据风险、划分完整性和测试集访问顺序写入审计证据。
漂移与群体覆盖	已生成	未观察到	TabularX 检查开发集与外部测试集的分布差异及已声明群体覆盖。
重载一致性	已生成	未观察到	TabularX 保存 reload_check.json，核对持久化前后预测是否一致。
交付状态与失败原因	已生成	未观察到	TabularX 保存 delivery.json，区分已生成、失败、缺失、未启用与不适用。
原生 HTML 报告	已生成	未观察到	TabularX 生成汇总 HTML；MLJAR Explain 本次主要输出逐模型 Markdown 与图片。

“未观察到”只表示本次配置和显式调用范围内没有找到对应工件，不外推为软件在任何条件下都不支持。

第 3 章　工具优缺点与结果解读

3.1　TabularX

优点：将测试集隔离、泄露与漂移审计、模型重载核验、报告生成和交付状态检查放入同一次运行的证据链。

不足：本次未观察到 ALE；当前小规模配置只能说明流程可运行，不能代表最优模型性能。

3.2　MLJAR

优点：Explain 模式能够生成逐模型 Markdown、学习曲线、混淆矩阵、特征重要性与 SHAP 等常规解释工件。

不足：本次运行目录中未观察到泄露与划分审计、漂移与群体覆盖、重载一致性、交付状态以及原生汇总 HTML 工件。

第 4 章　结　论

两种工具均完成主流模型训练和常规解释工件生成。MLJAR 的逐模型说明较成熟；TabularX 在常规模型报告之外补充可信审计、测试隔离、重载核验和交付状态证据。后续数据集继续复用相同的数据隔离、工件状态词和结果边界。

来　源

- 数据来源：OpenML dataset 31（credit-g）
- MLJAR supervised：https://github.com/mljar/mljar-supervised
- THUThesis：https://github.com/tuna/thuthesis