MLJAR 与 TabularX 完整工具包对比

数据集：Adult Income（OpenML dataset 1590（adult），二分类）。Adult Income 数据集包含 48,842 条人口统计记录和 14 个输入特征，目标是预测年收入是否超过 50,000 美元。

> 双方使用相同开发集和外部测试集；性能只描述本次固定配置，核心比较对象是实际生成的工件。

1. 外部测试集结果

工具	Accuracy	Balanced Accuracy	Macro-F1	混淆矩阵	ROC-AUC
TabularX	0.8757	0.7981	0.8175	[[7037, 394], [820, 1518]]	0.9284
MLJAR	0.8572	0.7752	0.7915	[[6929, 502], [893, 1445]]	0.9120

2. 工件盘点

工件	TabularX	MLJAR	TabularX 证据	MLJAR 证据
最佳模型及可重载文件	生成并核验	生成并核验	pipeline.joblib	1_Default_LightGBM/learner_fold_0.lightgbm； 1_Default_LightGBM_SampleWeigthing/learner_fold_0.lightgbm； 1_Default_LightGBM_SampleWeigthing_Update_1/learner_fold_0.lightgbm
候选模型与验证分数	生成并核验	生成并核验	evidence/model_scores.json	leaderboard.csv；params.json
预处理记录	生成并核验	生成并核验	reports/preprocess.html	1_Default_LightGBM/README.md； 1_Default_LightGBM_SampleWeigthing/README.md； 1_Default_LightGBM_SampleWeigthing_Update_1/README.md
特征重要性	生成并核验	生成并核验	reports/assets/lightgbm_shap_importance.png	1_Default_LightGBM/learner_fold_0_importance.csv； 1_Default_LightGBM/permutation_importance.png； 1_Default_LightGBM_SampleWeigthing/learner_fold_0_importance.csv
SHAP	生成并核验	生成并核验	reports/assets/lightgbm_shap_summary.png	4_Default_RandomForest/learner_fold_0_shap_summary.png； 4_Default_RandomForest_SampleWeigthing/learner_fold_0_shap_summary.png
ALE	未观测	未观测		
学习曲线或调参轨迹	生成并核验	生成并核验	reports/assets/lightgbm_trial_trajectory.png； reports/assets/random_forest_trial_trajectory.png； reports/assets/xgboost_trial_trajectory.png	1_Default_LightGBM/learning_curves.png； 1_Default_LightGBM_SampleWeigthing/learning_curves.png； 1_Default_LightGBM_SampleWeigthing_Update_1/learning_curves.png
混淆矩阵	生成并核验	生成并核验	reports/assets/lightgbm_confusion_matrix.png	1_Default_LightGBM/confusion_matrix.png； 1_Default_LightGBM/confusion_matrix_normalized.png； 1_Default_LightGBM_SampleWeigthing/confusion_matrix.png
公平性	生成并核验	生成并核验	evidence/fairness.json	performance_vs_fairness_sex.png

工件	TabularX	MLJAR	TabularX 证据	MLJAR 证据
泄露、划分与评估协议审计	生成并核验	未观测	evidence/audit.json；evidence/model_search_audit.json	
漂移与群体覆盖	生成并核验	未观测	evidence/audit.json	
重载一致性	生成并核验	未观测	evidence/reload_check.json	
交付状态与失败原因	生成并核验	未观测	evidence/delivery.json	
原生 HTML 报告	生成并核验	未观测	report.html	

3. 对比结果

- **TabularX**：将测试隔离、可信审计、模型重载核验和交付状态纳入同一次运行。
- **MLJAR**：Explain 模式提供逐模型说明、学习曲线、混淆矩阵和特征重要性。
- TabularX 最佳模型：lightgbm；MLJAR 最佳模型：Ensemble。

4. 运行信息

TabularX：21.6 秒；MLJAR：94.7 秒；随机种子 42。

“未观测”只表示本次固定配置的运行目录中没有找到相应工件，不外推为软件在任何条件下均不支持。