MLJAR 与 TabularX 十数据集完整工具包对比报告

> 本报告汇总十个公开表格数据集上的固定配置实验。性能指标用于描述本次运行，不构成严格等预算的普遍性能排名；“未观测”仅指本次运行目录中未找到对应工件。

1. 实验设计

实验覆盖八个分类任务和两个回归任务。每个数据集按随机种子 42 划分为 80% 开发集与 20% 外部测试集；外部测试集仅在两种工具完成训练与模型选择后评估一次。候选算法统一为随机森林、XGBoost、LightGBM 与 CatBoost。

2. 分类任务外部测试结果

数据集	任务	工具	Accuracy	Balanced Accuracy	Macro-F1	ROC-AUC
Bank Marketing	二分类	TabularX	0.9085	0.7108	0.7430	0.9343
Bank Marketing	二分类	MLJAR	0.9113	0.7616	0.7746	0.9337
Credit Scoring	二分类	TabularX	0.7450	0.6321	0.6427	0.7393
Credit Scoring	二分类	MLJAR	0.7450	0.5940	0.5899	0.7656
Employee Attrition	二分类	TabularX	0.8435	0.5968	0.6175	0.7151
Employee Attrition	二分类	MLJAR	0.7347	0.7129	0.6379	0.7708
Wine	三分类	TabularX	0.9722	0.9762	0.9743	1.0000
Wine	三分类	MLJAR	1.0000	1.0000	1.0000	1.0000
Adult Income	二分类	TabularX	0.8757	0.7981	0.8175	0.9284
Adult Income	二分类	MLJAR	0.8572	0.7752	0.7915	0.9120
Breast Cancer Wisconsin	二分类	TabularX	0.9825	0.9762	0.9810	0.9947
Breast Cancer Wisconsin	二分类	MLJAR	0.9737	0.9692	0.9716	0.9931
Titanic	二分类	TabularX	0.6201	0.5856	0.5865	0.6257

数据集	任务	工具	Accuracy	Balanced Accuracy	Macro-F1	ROC-AUC
Titanic	二分类	MLJAR	0.6425	0.6578	0.6399	0.7028
Iris	三分类	TabularX	0.9333	0.9333	0.9333	0.9867
Iris	三分类	MLJAR	0.9667	0.9667	0.9666	0.9900

3. 回归任务外部测试结果

数据集	任务	工具	MAE	RMSE	R2
House Prices	回归	TabularX	17990.9947	29635.3761	0.8855
House Prices	回归	MLJAR	16106.6117	27228.6840	0.9033
California Housing	回归	TabularX	0.3104	0.4649	0.8350
California Housing	回归	MLJAR	0.2811	0.4451	0.8488

4. 跨数据集工件观察次数

工件	TabularX 观察次数	MLJAR 观察次数
ALE	0	0
PDF 报告	1	0
SHAP	10	10
交付状态与失败原因	10	0
候选模型与验证分数	10	10
公平性	5	5
原生 HTML 报告	10	0
学习曲线或调参轨迹	10	10
最佳模型及可重载文件	10	10
泄露、划分与评估协议审计	10	0
混淆矩阵	8	8
漂移与群体覆盖	10	0

工件	TabularX 观察次数	MLJAR 观察次数
特征重要性	10	10
重载一致性	10	0
预处理记录	10	10

5. 工件状态汇总

工具	状态	数量
TabularX	生成并核验	124
TabularX	未观测	11
TabularX	不适用	6
MLJAR	生成并核验	73
MLJAR	未观测	62
MLJAR	不适用	6

6. 结果边界

- 两种工具采用相同外部测试集与算法集合，但搜索机制和公平性缓解流程并非严格等价，因此不将性能差异解释为工具的普遍优劣。
- Adult 与 Titanic 使用具有明确语义的敏感字段进行分组审计；Bank Marketing 与 Credit Scoring 的年龄分组属于预先声明阈值下的探索性审计。
- 公平性差异用于描述群体结果，不单独证明模型公平，也不替代场景规范与因果分析。

> **综合结论：**两种工具均能够完成主流模型训练并生成常规解释工件。跨数据集结果显示，TabularX 的主要增量集中在测试隔离、运行审计、模型重载核验以及工件状态与失败原因的统一交付；该结论指向证据交付流程的工程差异，不等同于预测性能优势。