# MLJAR 与 TabularX 完整工具包对比

Titanic 数据集实验报告

TabularX 机器学习课程项目

实验日期：2026 年 9 月 30 日

# 目 录

第 1 章 实验概述 ..... 1
1.1 数据集与任务 ..... 1
1.2 比较范围与原则 ..... 1
第 2 章 实验结果 ..... 2
2.1 外部测试集表现 ..... 2
2.2 可解释性与可信性工件盘点 ..... 2
第 3 章 工具优缺点与结果解读 ..... 4
3.1 TabularX ..... 4
3.2 MLJAR ..... 4
第 4 章 结　论 ..... 5
来　源 ..... 6

# 第 1 章　实验概述

## 1.1　数据集与任务

**数据集：Titanic（Kaggle Titanic（仓库固定副本），二分类）。** Titanic 数据集包含 891 名乘客的舱位、年龄和家庭关系等信息，目标是预测乘客是否生还；标识和高基数文本列不进入模型。数据按固定随机种子 42 划分为 80% 开发集和 20% 外部测试集，外部测试集共 179 条记录。

## 1.2　比较范围与原则

实验比较 MLJAR 与 TabularX 两个完整工具包，范围包括预处理、模型搜索与选择、解释、公平性适用性、可信审计、模型持久化、报告和证据交付。双方使用同一数据划分，并运行 Random Forest、XGBoost、LightGBM 和 CatBoost。外部测试集不参与训练、调参和选模，只在最终模型锁定后评估一次。

性能指标只描述本次固定配置。主要比较对象是实际生成并能够核对的解释性与可信性工件。

# 第 2 章　实验结果

## 2.1　外部测试集表现

表 2.1　共同外部测试集上的模型表现

| 工具 | 最终模型 | Accuracy | Balanced Accuracy | Macro-F1 | ROC-AUC |
|---|---|---|---|---|---|
| TabularX | xgboost | 0.6201 | 0.5856 | 0.5865 | 0.6257 |
| MLJAR | Ensemble | 0.6425 | 0.6578 | 0.6399 | 0.7028 |

本次固定配置下，TabularX 与 MLJAR 的 Accuracy 分别为 0.6201 和 0.6425，ROC-AUC 分别为 0.6257 和 0.7028。类别不均衡任务还应结合 Balanced Accuracy、Macro-F1 与混淆矩阵解读；该结果不构成普遍性能排名。

## 2.2　可解释性与可信性工件盘点

表 2.2　本次运行实际观察到的工件

| 工件 | TabularX | MLJAR | 说明 |
|---|---|---|---|
| 最佳模型及可重载文件 | 已生成 | 已生成 | 两者均保存最终模型；TabularX 另行核验模型接收原始表格后的预测一致性。 |
| 候选模型与验证分数 | 已生成 | 已生成 | TabularX 保存 model_scores.json；MLJAR 保存 leaderboard.csv 或参数记录。 |
| 预处理记录 | 已生成 | 已生成 | 两者均提供本次运行可查阅的预处理记录。 |
| 特征重要性 | 已生成 | 已生成 | 两者均生成特征重要性文件或图。 |
| SHAP | 已生成 | 已生成 | 两者本次均观察到 SHAP 工件；覆盖范围以实际模型目录为准。 |
| ALE | 未观察到 | 未观察到 | 本次固定配置下，两者均未观察到 ALE 工件。 |
| 学习曲线或调参轨迹 | 已生成 | 已生成 | TabularX 输出调参轨迹；MLJAR 输出学习曲线。 |

| 工件 | TabularX | MLJAR | 说明 |
| --- | --- | --- | --- |
| 混淆矩阵 | 已生成 | 已生成 | 分类任务用于核对各类别预测错误；回归任务不适用。 |
| 公平性 | 已生成 | 已生成 | 按 Sex 生成公平性与群体覆盖结果；Sex 用于分组审计，不进入两种工具的模型输入。 |
| 泄露、划分与评估协议审计 | 已生成 | 未观察到 | TabularX 将数据风险、划分完整性和测试集访问顺序写入审计证据。 |
| 漂移与群体覆盖 | 已生成 | 未观察到 | TabularX 检查开发集与外部测试集的分布差异及已声明群体覆盖。 |
| 重载一致性 | 已生成 | 未观察到 | TabularX 保存 reload_check.json，核对持久化前后预测是否一致。 |
| 交付状态与失败原因 | 已生成 | 未观察到 | TabularX 保存 delivery.json，区分已生成、失败、缺失、未启用与不适用。 |
| 原生 HTML 报告 | 已生成 | 未观察到 | TabularX 生成汇总 HTML；MLJAR Explain 本次主要输出逐模型 Markdown 与图片。 |

“未观察到”只表示本次配置和显式调用范围内没有找到对应工件，不外推为软件在任何条件下都不支持。

# 第 3 章　工具优缺点与结果解读

## 3.1　TabularX

**优点：**将测试集隔离、泄露与漂移审计、模型重载核验、报告生成和交付状态检查放入同一次运行的证据链。

**不足：**本次未观察到 ALE；当前小规模配置只能说明流程可运行，不能代表最优模型性能。

## 3.2　MLJAR

**优点：**Explain 模式能够生成逐模型 Markdown、学习曲线、混淆矩阵、特征重要性与 SHAP 等常规解释工件。

**不足：**本次运行目录中未观察到泄露与划分审计、漂移与群体覆盖、重载一致性、交付状态以及原生汇总 HTML 工件。

# 第 4 章　结　论

两种工具均完成主流模型训练和常规解释工件生成。MLJAR 的逐模型说明较成熟；TabularX 在常规模型报告之外补充可信审计、测试隔离、重载核验和交付状态证据。后续数据集继续复用相同的数据隔离、工件状态词和结果边界。

# 来　源

- 数据来源：Kaggle Titanic（仓库固定副本）
- MLJAR supervised：https://github.com/mljar/mljar-supervised
- THUThesis：https://github.com/tuna/thuthesis