TabularX TrustGuard 可信建模报告

从“模型能解释”进一步回答“实验结论是否值得相信”。

> **主实验数据集：**sklearn 乳腺癌数据集（来源：scikit-learn:breast_cancer；OpenI 正式运行；569 行、30 个特征；任务类型：二分类）。第 1—4 部分均基于该数据集；第 5 部分使用独立的公开数据集进行 MLJAR 对比实验。

执行摘要

总体风险	高/严重泄露发现	测试集访问次数
中等	**0**	**1**

评估协议状态

已完成且合规

> **总体结论：**未发现已确认的严重泄露，但存在需要人工复核的漂移或疑似风险。

关键实验结论

- 共完成 4 个候选模型的验证集评估，最终选择 LightGBM。
- 最终测试集访问 1 次，评估协议合规。
- MLJAR 对比实验成功完成 5 个公开数据集，失败 1 个。
- 5 个成功数据集均识别出目标复制和高唯一性 ID 注入风险，具体证据见第 5 部分。

1. 数据泄露审计 LeakageAuditor

> **内容：**检查目标复制、目标代理、高唯一性或 ID 字段、跨划分重复样本；在提供业务字段时，还检查实体分组泄露和时间穿越。审计只给出证据和建议，不静默修改原始数据。

结果

风险等级：**提示**；高/严重风险 0 项；建议排除字段：无。

1.1 检查项结果

检查项	状态	结果
目标复制	通过	未发现特征与目标逐行相同。
目标代理	通过	未发现超过阈值的疑似目标代理特征。
ID/高唯一性字段	通过	未发现疑似 ID 或高唯一性字段。
跨集合重复	通过	重复数为 0。
实体分组泄露	未执行	未指定 group_column，无法判断同一实体是否跨集合出现。
时间穿越	未执行	未指定 time_column，无法检查训练、验证与测试数据的时间顺序。

1.2 风险发现明细

等级	发现	证据	建议
未发现自动规则能够确认的泄露风险。			

> **解读：**未发现自动规则能够确认的高风险泄露；这不等于业务语义已被证明安全，应继续回答报告中的模型信息问题。

2. 评估协议守卫 EvaluationProtocolGuard

> **内容：**用状态机约束“验证集选择候选模型 → 锁定唯一模型 → 测试集仅评估一次”。任何提前访问、换模型或二次访问都会抛出异常并留下日志。

结果

协议规则	候选模型只根据验证集选择；测试集仅允许被最终锁定的模型访问一次。
状态	已完成且合规
候选模型	["random_forest", "xgboost", "lightgbm", "catboost"]
锁定模型	lightgbm
测试集访问	1

> **解读：**模型按验证集完成选择，测试集只被锁定模型访问一次，协议记录完整。

2.1 候选模型验证结果

主要选择指标：`ROC-AUC`（越大越好）。

模型	运行状态	主要验证指标	准确率	F1	ROC-AUC	失败原因
随机森林	成功	0.987553	0.956140	0.965035	0.987553	—
XGBoost	成功	0.992139	0.964912	0.971831	0.992139	—
LightGBM	成功	0.994104	0.964912	0.971831	0.994104	—
CatBoost	成功	0.990174	0.947368	0.958333	0.990174	—

解读：LightGBM 根据验证集 ROC-AUC 被选为最终模型，验证集 ROC-AUC=0.994104。模型锁定后才访问一次测试集，最终测试指标为：准确率=0.956140、平衡准确率=0.945437、F1=0.965986、宏平均 F1=0.952129、ROC-AUC=0.986111、精确率=0.946667、召回率=0.986111。测试结果没有参与候选模型排名。

3. 可复现实验证据 ReproducibilityLedger

内容：记录数据指纹、划分索引及哈希、运行参数、命令、Python/操作系统和关键依赖版本，并对最终工件生成 SHA-256 清单；原始特征值和目标值不会复制进报告目录。

结果

数据规模	569 行 × 30 列
数据指纹	`fb2ffaee659f439c53544cd2682543cbcc5ee0bf644d3c180176f8bbf450f44d`
生成时间（UTC）	2026-09-20T13:18:41.652416+00:00
运行命令	`sklearn breast cancer; RF/XGBoost/LightGBM/CatBoost; 5 Optuna trials per model`
Python	3.10.13 (main, Sep 11 2023, 13:44:35) [GCC 11.2.0]
平台	Linux-4.15.0-112-generic-x86_64-with-glibc2.35

划分证据

划分	样本数	索引 SHA-256
训练集	341	`eb8f763209d46a68d79b01ee344cb41ae38c667f92f66fec08d29e8eca2bb273`
验证集	114	`51db88483b91ba9101e61479e7fe1cc8c6329d3cd277751fb163c44f50676a34`
测试集	114	`0a2018f79e32c8dd82733658de70d76bece5e527f1826d90118891817717a8c4`

解读：相同输入、索引、配置和依赖应得到可复核的实验；清单校验失败意味着工件在生成后被修改、删除或新增，需要重新核验。

4. 特征漂移与群体覆盖 DistributionAudit

> **内容：**以训练集为基准，数值特征计算 PSI 与经验 KS，类别特征计算总变差距离（TVD）及未见类别比例；对敏感属性统计每个群体在训练集、验证集和测试集中的样本量，包括完全缺失（0 条）的群体。

4.1 高风险优先的漂移结果

共生成 60 条比较记录。正文仅展示风险最高的 15 条，完整明细保存在 `distribution_audit/feature_drift.csv`。

特征	比较	PSI	KS	TVD	未见类别率	等级
mean radius	训练集 vs 验证集	0.232363	0.072516	—	—	中等
mean area	训练集 vs 验证集	0.231110	0.078330	—	—	中等
texture error	训练集 vs 测试集	0.218315	0.109533	—	—	中等
perimeter error	训练集 vs 验证集	0.182148	0.089700	—	—	中等
worst concavity	训练集 vs 测试集	0.178711	0.114601	—	—	中等
mean perimeter	训练集 vs 验证集	0.175831	0.072465	—	—	中等
fractal dimension error	训练集 vs 测试集	0.172880	0.097597	—	—	中等
fractal dimension error	训练集 vs 验证集	0.166242	0.125251	—	—	中等
worst concave points	训练集 vs 测试集	0.158979	0.112646	—	—	中等
mean smoothness	训练集 vs 验证集	0.067704	0.156377	—	—	中等
worst smoothness	训练集 vs 测试集	0.148543	0.062252	—	—	中等
mean symmetry	训练集 vs 验证集	0.143392	0.089803	—	—	中等
mean fractal dimension	训练集 vs 测试集	0.134512	0.079539	—	—	中等
symmetry error	训练集 vs 测试集	0.133861	0.091141	—	—	中等
mean compactness	训练集 vs 验证集	0.093593	0.130035	—	—	中等

4.2 敏感群体覆盖

敏感特征	群体	划分	样本量	占比	等级
本次数据集未指定敏感特征，因此群体覆盖审计不适用。					

> **解读：**未发现高风险分布差异。中等风险指标仍应结合样本量和业务变化解释，不能只凭阈值判断模型可部署。

5. MLJAR 可解释性工件对比实验

> **实验目的：**在相同公开数据集上盘点 MLJAR Explain 与 TrustGuard 默认生成的工件，并通过注入目标复制、ID、跨划分重复或未来信号验证风险审计能否报警。该实验比较“报告和审计工件完整性”，不把不同搜索策略下的模型分数当作严格算法排名。

数据集：6 个；成功：5 个；失败：1 个。失败记录会保留在表中，不从结论中隐藏。

数据集	状态	MLJAR 解释工件	MLJAR 可信性工件	TrustGuard 四类工件	泄露注入检测	结论
diabetes	成功	4/6：报告、特征重要性、混淆矩阵、学习曲线	0/4：无	4/4： 泄露审计、测试访问日志、复现证据、分布审计	成功	目标复制和高唯一性 ID 风险均被识别。
spambase	成功	4/6：报告、特征重要性、混淆矩阵、学习曲线	0/4：无	4/4： 泄露审计、测试访问日志、复现证据、分布审计	成功	目标复制和高唯一性 ID 风险均被识别。
adult	成功	4/6：报告、特征重要性、混淆矩阵、学习曲线	0/4：无	4/4： 泄露审计、测试访问日志、复现证据、分布审计	成功	目标复制和高唯一性 ID 风险均被识别。同时生成 21 条敏感群体覆盖记录。
car	成功	4/6：报告、特征重要性、混淆矩阵、学习曲线	0/4：无	4/4： 泄露审计、测试访问日志、复现证据、分布审计	成功	目标复制和高唯一性 ID 风险均被识别。
kr-vs-kp	成功	4/6：报告、特征重要性、混淆矩阵、学习曲线	0/4：无	4/4： 泄露审计、测试访问日志、复现证据、分布审计	成功	目标复制和高唯一性 ID 风险均被识别。
credit-g	失败	运行失败	运行失败	运行失败	未执行	OpenML 数据接口在训练前读取超时；该记录被保留，未计入成功数据集结论。

> **解读：**共成功完成 5 个公开数据集。MLJAR Explain 的工件盘点结果与 TrustGuard 的可信性工件互补；TrustGuard 在 5 个成功数据集上均生成四类可信性工件，并在 5 个数据集上识别全部注入风险。失败数据集及其原因被如实保留，没有从汇总中删除。

6. 结论与使用边界

TrustGuard 报告是模型性能、SHAP、混淆矩阵和公平性报告的可信性补充，而不是替代。自动规则只能发现可计算的异常；业务字段是否在预测时可获得、时间窗口是否合理，仍需数据负责人确认。高风险发现应在模型发布前处理并重新运行完整流水线。